MASTER OF SCIENCE
IN ENGINEERING

Automatisation de la saisie des heures avec Machine Learning

Auteur Fontaine Loïc
Master of Science HES-SO in Engineering
Spécialisation en Computer Science
Sous la supervision de Albertetti Fabrizio
En collaboration avec Liip SA

Introduction

La saisie manuelle des temps de travail est une corvée administrative souvent reportée, ce qui nuit à la précision de la facturation. Ce projet propose une solution capable de transformer automatiquement l'activité numérique d'un collaborateur en suggestions de feuilles de temps cohérentes.

Contexte et objectifs

- **Problématique:** Chez Liip, le délai moyen de saisie est de 2,26 jours, entraînant des oublis pour 90 % des employés.
- **Objectif principal**: Développer un système proactif qui préremplit les quatre champs clés de l'outil Zebra : projet, activité, rôle et durée.
- **Enjeu:** Réduire la charge mentale administrative sans compromettre la confidentialité des données.

Méthodes

Le système traite les traces numériques issues de GitLab (développement), YouTrack (tickets) et Google Calendar (réunions) via un pipeline en deux étapes :

1. **Estimation Macro (Durée) :** Un modèle de boosting (LightGBM) prédit le temps total travaillé par jour en traitant la "zéro-inflation" (jours non travaillés).
2. **Affectation Micro (Classification) :** La journée est découpée en intervalles de 15 minutes. Chaque bloc est associé à un projet par appariement sémantique multilingue (embeddings) pour gérer un catalogue de plus de 1'000 projets actifs.

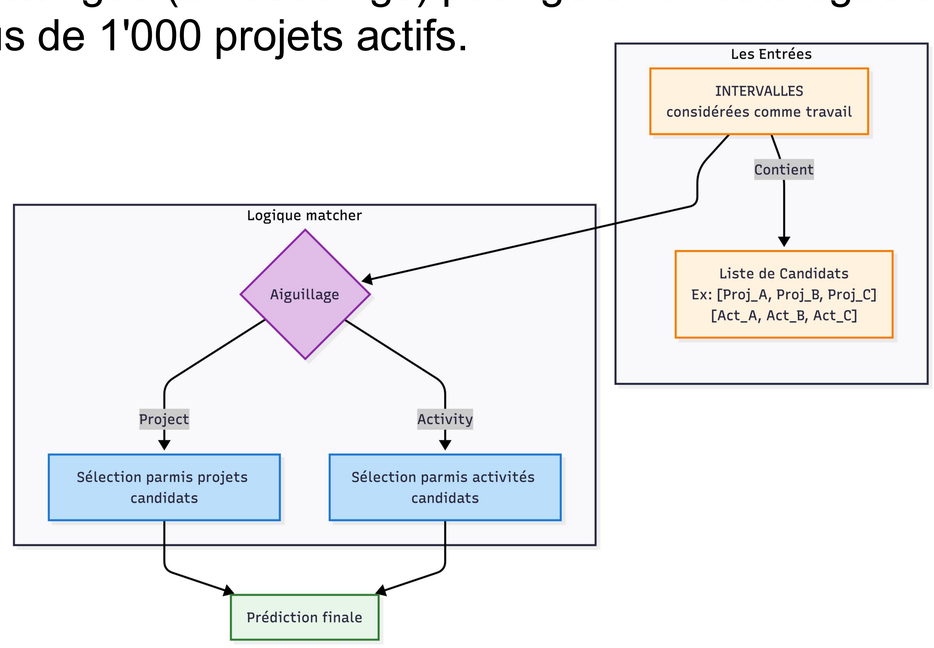

Figure 1. Schéma des prédictions par intervalle

Résultats

- Prédiction de la durée: Excellente performance avec une erreur absolue moyenne de seulement 25 minutes par jour.
- Identification des projets : Un taux de succès de 38 % est atteint. Le modèle sémantique hybride (Dual Semantic) se révèle le plus robuste pour équilibrer les prédictions entre projets fréquents et rares.
- Impact du volume : La précision augmente avec la densité des logs numériques, validant l'utilisation des traces comme "proxy" de l'activité.

Métrique	Modèle Hurdle (Durée)	Matcher Sémantique	Matcher Sémantique hybride
Performance	MAE : 0.42 h	Accuracy : 38 % Pour les projets	Accuracy: 32% Pour les projets
Performance 2	-	F1 pondéré 30% Pour les projets	F1 pondéré: 33% Pour les projets

Tableau 1. Performances des modèles

Conclusion

Le travail démontre qu'une automatisation assistée est viable. Si la prédiction des volumes horaires est très robuste, la classification fine des projets reste un défi technologique complexe.

- **Limites:** Dépendance à l'activité connectée et bruit dans les données déclaratives humaines
- **Perspective:** L'intégration de l'apprentissage actif (Active Learning) permettra au modèle de s'améliorer en continu grâce aux corrections des utilisateurs

Remerciements

Je tiens à remercier Albertetti Fabrizio mon superviseur académique ainsi que Jeanmonod qui m'a suivi chez Liip

Références

A. N. Meyer et al. (2022). *Detecting Developers'Task Switches and Types*
Devlin, J. et al. (2018). *BERT: Pre-Training of Deep Biderctional Transformers for Language Understanding.*
Halfaker, A. et al. (2015). *User Session Identification Based on Strong Regularities in Inter-activity Time.*

Hes·so
Master